Hands-On Machine Learning

Chapter 1 — The Machine Learning Landscape

Types · Challenges · Testing & Validating

ملخص كشكولك + تكملة النقط الناقصة + رسومات وأكواد للمراجعة

من كشكولك | إضافة لإكمال النقص | انتبه / تصحيح

الأرقام في مربعات **Output (real run)** الخضرا طلعت من تشغيل الكود فعلًا (بيانات lifesat.csv الحقيقية بتاعة الكتاب، وبيانات digits الحقيقية من sklearn). الرسومات اللي عليها (synthetic) داتا مولّدة للتوضيح فقط.

---

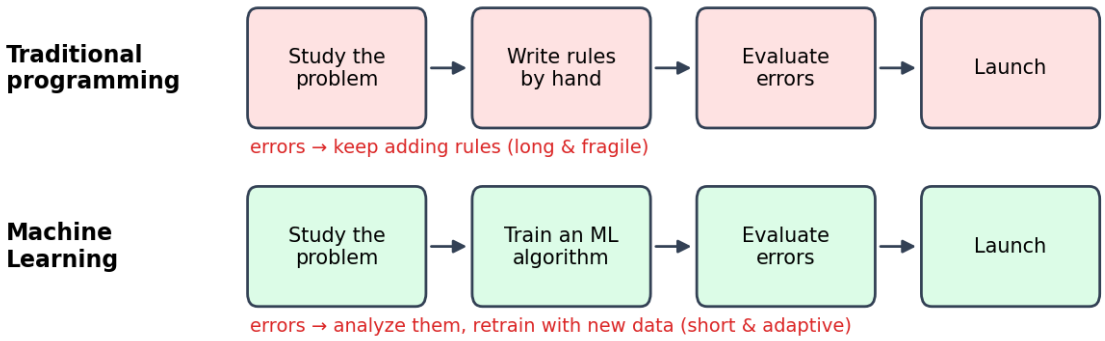
1 يعني إيه Machine Learning؟

من كشكولك

المعلومة اللي وضعت التعريف وكان أول واحد يضع المصطلح هو Arthur Samuel سنة 1959 ، وكان بيشتغل في الذكاء الاصطناعي.

> *Machine learning is the field of study that gives computers the ability to learn without being explicitly programmed.*

التعلم الآلي: هو مجال الدراسة الذي يمنح أجهزة الكمبيوتر القدرة على التعلم دون برمجتها بشكل صريح.



الفرق بين البرمجة التقليدية وال ML: في التقليدية بتكتب القواعد بإيدك وتفضل تزودها لما تلاقي أخطاء، وفي ال ML بتدّرب خوارزمية على داتا وتعيد التدريب بداتا جديدة لما تلاقي أخطاء.

إضافة

تعريف تاني أكتر هندسية بيذكره الكتاب (Tom Mitchell، 1997):

> *A computer program is said to learn from experience E with respect to some task T and some performance measure P, if its performance on T, as measured by P, improves with experience E.*

- `T` = المهمة (Task) زي: تصنيف إيميل spam / ham.
- `E` = الخبرة (Experience) = الداتا اللي بنتدرب عليها، وكل مثال تدريب اسمه training instance أو sample، ومجموعتهم training set.
- `P` = مقياس الأداء (Performance measure) زي الـ accuracy.

مثال: الـ spam filter: ال `T` تصنيف الإيميلات، و `E` إيميلات اتصنّفت قبل كده، و `P` نسبة الإيميلات اللي اتصنّفت صح.

من كشكولك

> *Applying ML techniques to dig into large amounts of data can help discover patterns that were not immediately apparent. This is called data mining.*

إن تطبيق تقنيات التعلم الآلي للتنقيب في كميات كبيرة من البيانات يُساعد على اكتشاف أنماط (patterns) لم تكن واضحة للوهلة الأولى، وهذا ما يسمى Data mining (استخراج البيانات).

الـ ML ممتاز في إيه؟

من كشكولك

1. **مشاكل الحلول الحالية فيها محتاجة** hand-tuning **كتير أو قوائم قواعد طويلة** (long lists of rules): الـ ML غالبًا بيبسّط الكود.
2. **مشاكل معقدة مفيش ليها حل كويس خالص** باستخدام النهج التقليدي.
3. **البيئات المتقلبة** (Fluctuating environments): نظام التعلم الآلي ممكن يتكيف مع البيانات الجديدة.
4. **الحصول على رؤى (insights)** حول المشاكل المعقدة وكميات كبيرة من البيانات.

إضافة

أمثلة لكل نقطة (من نفس سياق الكتاب): (1) الـ spam filter: بدل قواعد طويلة بتتغيّر كل يوم. (2) التعرف على الكلام (speech recognition): معقد جدًا لدرجة إن القواعد اليدوية ما بتنفعش. (3) spam filter بيتعلّم الكلمات الجديدة اللي المرسلين بيخترعوها تلقائيًا من غير ما تعدّل الكود. (4) الـ data mining اللي فوق.

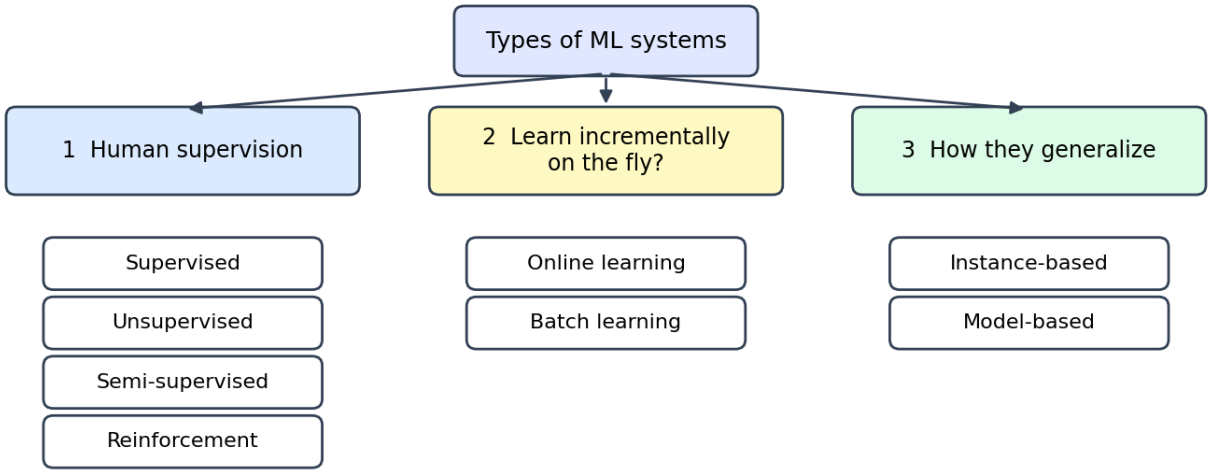
2 أنواع أنظمة الـ ML (التصنيف بـ 3 معايير)

من كشكولك

① **human supervision** (مدى الإشراف البشري أثناء التدريب): Supervised (التعلم الخاضع للإشراف) · Unsupervised (التعلم غير الخاضع للإشراف) · Semi-supervised (التعلم شبه الخاضع للإشراف) · Reinforcement Learning (التعلم المعزز).

② **Learn incrementally on the fly**: هل النظام بيتعلم تدريجيًا وهو شغّال؟ (online versus batch learning: التعلم عبر الإنترنت مقابل التعلم بالدُفعات).

③ **Comparing new data points**: دي بتتكلم عن إنها بتعمل مقارنة لنقاط البيانات الجديدة بنقاط البيانات المعروفة، أو بدلًا من ذلك بتكتشف الأنماط في بيانات التدريب وتبني نموذجًا تنبؤيًا تمامًا كما يفعل العلماء. (instance-based versus model-based learning).



الـ 3 معايير مستقلة عن بعض: نظام واحد ممكن يبقى supervised + online + model-based في نفس الوقت (زي الـ spam filter).

من كشكولك

ملحوظة: دي أنواع/أساليب/طرق تعلّم ال ML، مش أنواع حصرية؛ ممكن النظام الواحد يجمع من كل معيار حاجة.

3 الـ Supervised Learning

من كشكولك

> *Supervised learning: the training data you feed to the algorithm includes the desired solutions, called labels.*

تتضمن بيانات التدريب التي تدخلها إلى الخوارزمية الحلول المطلوبة والتي تسمى التصنيفات (labels).

يعني أنا محتاج أدّي الموديل داتا وإجاباتها معروفة. مثال: أدّيه صور للحاجة اللي هو هيتعلمها، فيبقى عندي: `X -> y`، الـ input هو `X`، والناتج اسمه الـ label (output).

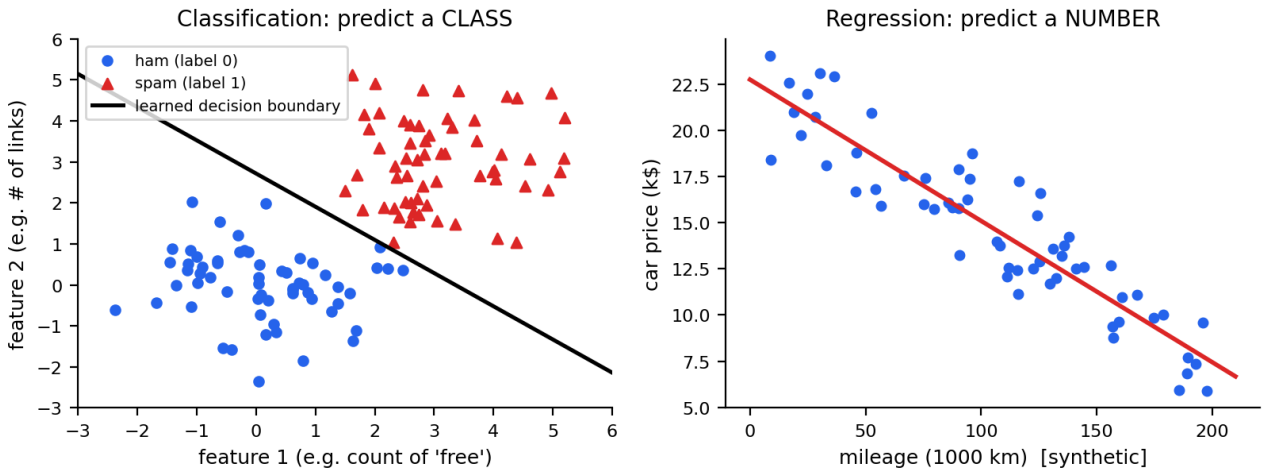
من كشكولك

① Classification

بدّي للموديل داتا (Classification) جواها أمثلة عن الحاجة وهو يتعلم منها: لو لقى كذا يطلع كذا، ولو وصل لـ 1+1 يعني زي كده وهكذا. ومثال برضه الـ spam filter: بتدّي الموديل داتا فيها إيميلات وكل واحد متصنّف، ولو لقى شكل كذا يبقى ده spam وده مش spam، ويتعلم إزاي يصنّف إيميل جديد.

② Regression

بدّي للموديل داتا جواها بيانات بمختلف الأشكال، فهو هيعمل prediction لقيمة رقمية مطلوبة (target)، يعني مثلًا: قلتله سعر العربية دي كام؟ فهو بيبني على الـ data set يعني بيعتمد على نوع العربية وبيقارنها ببيانات (كل داتا الأسعار) وبيقارن كل حاجة وبيقولك السعر في النهاية.



شمال: Classification بتتنبأ بفئة (spam / ham) والخط الأسود هو الحد الفاصل اللي اتعلمه الموديل. يمين: Regression بتتنبأ برقم (سعر العربية). الاتنين من تشغيل حقيقي على داتا synthetic.

من كشكولك

أهم خوارزميات الـ Supervised (في الكتاب):

1. k-Nearest Neighbors
2. Linear Regression (الانحدار الخطي)
3. Logistic Regression (الانحدار اللوجستي)
4. Support Vector Machines (SVMs) (آلات المتجهات الداعمة)
5. Decision Trees and Random Forests (أشجار القرار والغابات العشوائية)
6. Neural networks (الشبكات العصبية)

إضافة

- target و label غالبًا مترادفين، لكن `target` أشهر في الـ regression و`label` أشهر في الـ classification. والـ features بتتسمى كمان predictors أو attributes.
- بعض خوارزميات الـ regression ممكن تتستخدم للتصنيف والعكس: Logistic Regression مثلًا بتدّيك احتمال إن الإيميل spam (تقدير بين 0 و1) وبعدين تحوّله لفئة. (هنشوفها بالتفصيل في Chapter 4.)
- بعض معماريات الـ Neural Networks ممكن تكون unsupervised (زي autoencoders و restricted Boltzmann machines) أو semi-supervised.

4 الـ Unsupervised Learning

من كشكولك

> *Unsupervised learning: the training data is unlabeled. The system tries to learn without a teacher.*

بيانات التدريب غير معلّمة، يحاول النظام التعلّم بدون معلّم. يعني معايا داتا بس مفيش labels (output) لكل داتا. يعني دلوقتي مثلًا عندك مدونة وزوّارها كتير وعندك داتا عنهم (فيهم الجنس والسن والمنطقة...)، والمطلوب خوارزمية تحاول اكتشاف مجموعات من الزوّار المتشابهين. وانت ما بتقولش للخوارزمية أي زائر ينتمي لأنهي مجموعة: هي بتلاقي الروابط دي من غير مساعدتك.

من كشكولك

أهم خوارزميات الـ Unsupervised:

① **Clustering (تجميع):** k-Means · Hierarchical Cluster Analysis (HCA) (تحليل العنقود الهرمي) · Expectation Maximization.

② **Visualization and dimensionality reduction (التصور وتقليل الأبعاد):** Principal Component Analysis (PCA) (تحليل المكونات الرئيسية) · Kernel PCA (تحليل المكونات الرئيسية بالنواة) · Locally-Linear Embedding (LLE) (التضمين الخطي المحلي) · t-distributed Stochastic Neighbor Embedding (t-SNE) (تضمين الجوار العشوائي الموزّع).

③ **Association rule learning (تعلّم قواعد الارتباط):** Apriori · Eclat.

انتبه / تصحيح

القايمة اللي في كشكولك (فيها Expectation Maximization) هي قايمة الطبعات الأقدم. في الطبعة الثالثة من الكتاب الأمثلة المذكورة للـ clustering هي k-means و DBSCAN و HCA. EM مش غلط: هي الخوارزمية اللي بتتدرّب بيها الـ Gaussian Mixture Models (Chapter 9)، لكن ضيف DBSCAN في قايمتك. والكتاب كمان بيعدّد Anomaly detection كمهمة unsupervised مستقلة (isolation forest، one-class SVM)، وده موجود في كشكولك تحت.

من كشكولك

Clustering

لو معاك كتير من الصور (مثلًا) وعايز الـ clustering يقسّم الصور دي لكل شيء (المتشابهين) مع بعض من غير ما يحدد الصور دي إيه بالظبط. (مثال من الكتاب: زوّار المدونة).

```
from sklearn.cluster import KMeans
kmeans = KMeans(n_clusters=3, n_init=10, random_state=42)
kmeans.fit(X)                    # NO labels y are passed!
print(kmeans.cluster_centers_)   # the 3 group centers it discovered
```

Output (real run)

```
[[-8.54  5.57]
 [-1.26  4.39]
 [ 9.62  0.56]]
```

من كشكولك

Visualization algorithms

> *Visualization algorithms are also a good example of unsupervised learning algorithms: you feed them a lot of complex and unlabeled data, and they output a 2D or 3D representation of your data that can easily be plotted. These algorithms try to preserve as much structure as they can (e.g., trying to keep separate clusters in the input space from overlapping in the visualization), so you can understand how the data is organized and perhaps identify unsuspected patterns.*

الشرح (مش التوضيح): هي بتحوّل البيانات المعقدة من أبعاد كتير (مثلًا 100 أو 200 أو 300 feature) إلى 2D أو 3D عشان تقدر ترسمها وتشوف شكل البيانات بعينك، عشان أشوف: هل الداتا متجمعة في مجموعات؟ كام cluster موجود؟

وبتكتشف الـ outliers (النقط البعيدة جدًا). وبرضه بتخليك تفهم الداتا: overlapping (هل فيه مجموعتين من البيانات داخلين في بعض ومش واضح حدودهم)، وهل linear ولا nonlinear (curves). فبالتالي لو فيه overlapping هيكون الـ classifier هيخلط كتير ومش هتقدر ترسم خط فاصل واضح بينهم، فالموديل محتاج Features أكتر تعقيدًا أو محتاج preprocessing إضافية.

من كشكولك

Dimensionality Reduction

هي عملية تقليل عدد الـ features مع الاحتفاظ بأكبر قدر من المعلومات المهمة (مثال: عدد الـ features كان 200 أو 300 يبقى 50 أو 20). ليه؟ الأساس إن الـ features الكتيرة بتخلّي الـ Computations كتيرة والتدريب بطيء، وبتزوّد خطر الـ overfitting لأن الموديل بيتوه وسط features كتير وبيتعلم الـ noise.

إضافة

مثال الـ feature extraction من الكتاب: مسافة العربية (mileage) مرتبطة بعمرها جدًا، فخوارزمية تقليل الأبعاد بتدمجهم في feature واحدة بتمثل "البلى والاستهلاك" (wear and tear). وفي الأمثلة اللي تحت: PCA على عمر العربية وعدد الكيلومترات (مترابطين جدًا) حافظ على 98% من المعلومات في محور واحد بس.

```
from sklearn.decomposition import PCA
pca = PCA(n_components=1)           # 2 correlated features  ->  1 axis
X_1d = pca.fit_transform(X_scaled)
print(pca.explained_variance_ratio_)
```

Output (real run)

```
[0.9759]   <- one axis keeps 97.6% of the information
```

تلميح مهم من الكتاب: جرّب تقلّل أبعاد الداتا قبل ما تدّيها لخوارزمية تانية (supervised)؛ هتبقى أسرع وبتاخد مساحة أقل، وفي بعض الحالات أداء أحسن.

من كشكولك

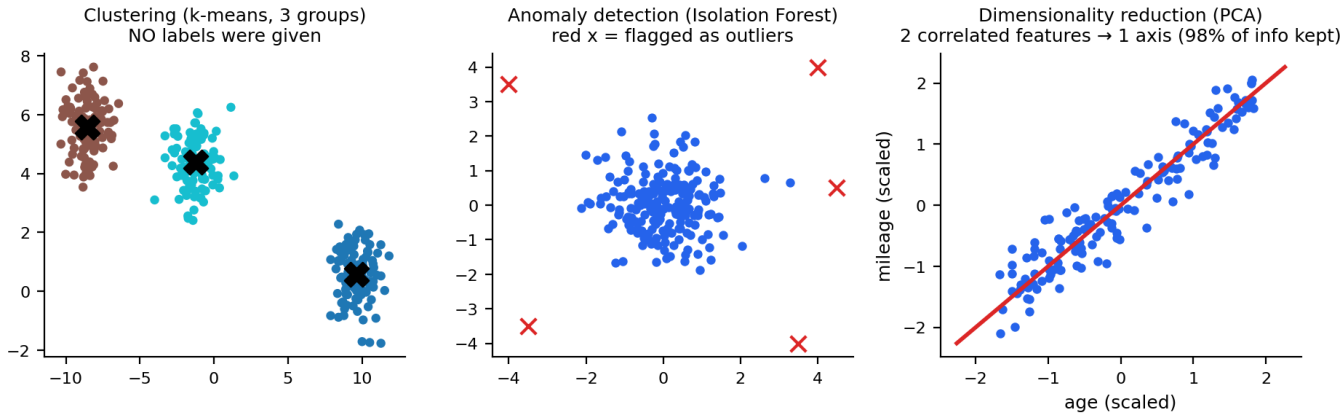
Anomaly detection (اكتشاف الشذوذ)

فكرتها بسيطة جدًا؛ عندك بيانات كلها طبيعية وعايز تعرف لو ظهر عنصر غريب مش شبه باقي البيانات. بتتدرب على بيانات طبيعية كتير (والحالات الغريبة قليلة) فتعمل system يحفظ الشكل الطبيعي، ولما يشوف نقطة بعيدة عنه يقول إن دي Anomaly / outliers.

```
from sklearn.ensemble import IsolationForest
iso = IsolationForest(contamination=0.025, random_state=42)
flags = iso.fit_predict(X)          # -1 = anomaly (outlier), 1 = normal
print((flags == -1).sum(), "points flagged")
```

Output (real run)

```
5 points flagged
```



الـ 3 مهام الأساسية للـ unsupervised من تشغيل حقيقي (synthetic): تجميع من غير labels، اكتشاف الشواذ (x أحمر)، وتقليل البعد بـ PCA (98% من المعلومات في محور واحد).

من كشكولك

Association rule learning

خوارزميات بتبحث عن الارتباطات (العلاقات) بين العناصر جوه الداتا. **مثال مشهور:** لو واحد بيشتري Bread و Butter فاحتمال عالي يشتري Milk، فتقول قاعدة (`Bread + Butter ⇒ Milk`). وده بيفيد مثلًا في تجميع الأصناف اللي بتظهر مع بعض في الـ Clustering.

ملاحظة (قراءة تقريبية لكلامك): اكتشاف العلاقات والـ Patterns بدون labels ده أهم خطوة في الـ Machine Learning Pipeline، لأنك من غير ما تشوف الـ Patterns قبل ما تختار موديل هتختار موديل غلط وتعمل preprocessing غلط، وكل الـ Accuracy هتقع. (راجع الورقة: الخط في السطرين الأخيرين من صفحة الـ Unsupervised مش واضح تمامًا.)

إضافة

Anomaly detection مقابل Novelty detection (من الكتاب): الـ anomaly detection بتتدرب على داتا ممكن يكون فيها شوية outliers ومش لازم تكون نضيفة تمامًا؛ أما الـ novelty detection فبتحتاج training set نضيف (من غير الحاجة الغريبة اللي هتدور عليها). مثال: لو عندك ملايين صور كلاب فيها 1% شيواوا، الـ novelty detection مش المفروض تعتبر صورة شيواوا جديدة novelty، أما الـ anomaly detection ممكن تعتبرها شاذة.

5 الـ Semi-supervised و Self-supervised

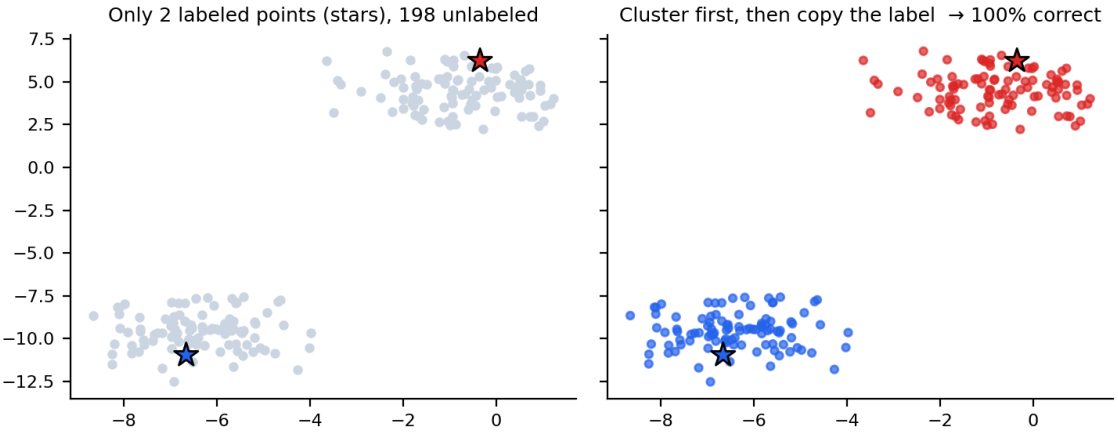
من كشكولك

> *Semi-supervised learning: some algorithms can deal with partially labeled training data, a lot of unlabeled data and a little bit of labeled data. This is called semi-supervised learning.*

يمكن لبعض الخوارزميات التعامل مع بيانات تدريب مصنّفة جزئيًا، وعادةً ما تكون الكثير من البيانات غير المصنّفة وقليل من البيانات المصنّفة.

معظم خوارزميات التعلم شبه الخاضع للإشراف هي تركيبة من خوارزميات غير خاضعة للإشراف و خاضعة للإشراف. مثل: Deep Belief Networks (DBNs): وهي مبنية على مكونات غير خاضعة للإشراف اسمها Restricted Boltzmann

Machines (RBMs) مكدّسة فوق بعضها. بعض يتم تدريب الـ RBMs بشكل تسلسلي بطريقة غير خاضعة للإشراف، ثم يتم ضبط النظام بأكمله باستخدام تقنيات التعلم الخاضع للإشراف.



فكرة الـ semi-supervised: نقطتين متصنفتين بس (النجمتين) تكفّي تسمّي كل الـ cluster لو الداتا متجمعة. (داتا synthetic سهلة عمدًا)

إضافة

مثال الكتاب: خدمات الصور زي Google Photos: بتتعرف إن الشخص نفسه ظهر في صور كتير (ده الجزء الـ unsupervised: clustering)، وبعدين تحتاج بس تقولها اسم الشخص مرة واحدة (label واحد) وهي تحط الاسم على كل صوره (supervised). وده مفيد جدًا لأن الـ labeling غالي ومحتاج وقت بشري.

Self-supervised learning (نوع مستقل في الطبعة الثالثة، مش موجود في كشكولك): الخوارزمية بتولّد labels من داتا unlabeled نفسها. مثال: تاخد صورة، تمسح جزء منها، وتخلّي الموديل يحاول يخمّن الجزء المفقود (الجزء الحقيقي هو الـ label). بعد كده الموديل ده بيتعلّم تمثيل كويس للصور، وتقدر تعمله fine-tuning على مهمة حقيقية بداتا labeled قليلة (زي تصنيف أنواع حيوانات).

6 الـ Reinforcement Learning

من كشكولك

> *Reinforcement learning is a very different beast. The learning system, called an agent in this context, can observe the environment, select and perform actions, and get rewards in return (or penalties in the form of negative rewards).*

التعلم المعزز هو شيء مختلف تمامًا. يمكن لنظام التعلّم الذي يُطلق عليه اسم الوكيل (agent) في السياق، مراقبة البيئة (environment)، واختيار الإجراءات وتنفيذها (actions)، والحصول على مكافآت (rewards) في المقابل (أو عقوبات على شكل مكافآت سلبية).

يجب عليه بعد ذلك أن يتعلم بنفسه ما هي أفضل استراتيجية، وتسمى سياسة (policy)، للحصول على أكبر قدر من المكافآت بمرور الوقت. تحدد السياسة الإجراء الذي يجب على الوكيل اختياره عندما يكون في موقف معيّن.

بعض التطبيقات للتعلم المعزز: برنامج AlphaGo من DeepMind وهو اللي هزم بطل العالم في لعبة Go.



goal: learn the policy that maximizes the total reward over time

دورة الـ RL: الـ agent بيعمل action، والـ environment بيرجّع observation + reward. المطلوب policy تحقق أكبر reward تراكمي.

7 جدول المقارنة (من كشكولك + إكمال الأعمدة الفاضية)

من كشكولك

الجدول اللي عملته في كشكولك بالإنجليزي (الأعمدة 1 لـ 4). الأعمدة 5 و6 (unsupervised, supervised) كانوا فاضيين، وكملتهم تحت (باللون البرتقالي).

	Online learning ①	Batch learning ②	Reinforcement ③	Semi- ④ supervised
Advantages	Handles large or infinite datasets · Good for real-time systems · Adapts quickly to new patterns · Low memory usage	Very accurate when data fixed · Training process is stable and easier to tune · You can preprocess the whole dataset before training	Learns optimal behaviors through trial and error · Good for sequential decisions · Does not require labeled data, only rewards	Reduces labeling cost · Good for domains where labels are expensive
Disadvantages	Harder to tune · Model may become unstable with noisy data · Cannot easily go back and correct earlier mistakes	Requires large memory and computation · Cannot adapt to new data unless retrained from scratch · Not suitable for real-time learning	Very slow and computationally expensive · Designing reward functions is hard · Can behave unpredictably if rewards are wrong	Methods can be complex · Wrong labels or assumptions can degrade performance (الأخطاء في الـ labels القليلة بتتنقل لكل الداتا)
Examples	Spam filters that update daily · Online recommendation systems · Stock market prediction systems	Training a neural network on ImageNet · Training a face recognition model on a large dataset	AlphaGo, AlphaZero · Self-driving car navigation · Robot control	(مكتوبة فاضية في الكشكول)

إضافة

الأعمدة اللي كانت فاضية، متكمّلة بنفس الأسلوب:

	⑤ Unsupervised	⑥ Supervised
Advantages	No labels needed (cheap data) · Discovers hidden structure/groups you didn't know about · Useful for visualization, anomaly detection and as a preprocessing step	Clear goal and easy to measure · Usually the most accurate when enough labeled data exists (...accuracy, RMSE) · Many mature algorithms
Disadvantages	Hard to evaluate: there is no 'correct answer' to compare with · Results can be hard to interpret · You must decide the number of clusters /components	Needs lots of LABELED data (expensive and slow to collect) · Learns the labelers mistakes and biases · Can overfit the training labels
Examples	Customer segmentation (k-means) · Anomaly detection of fraud · Dimensionality reduction with PCA	Spam filter (classification) · House/car price prediction (regression) · Digit recognition

8 الـ Batch Learning والـ Online Learning

من كشكولك

> *Batch learning: In it, the system is incapable of learning incrementally: it must be trained using all the available data.*

في التعلم الدفعي (Batch learning) يكون النظام غير قادر على التعلم بشكل تدريجي؛ يجب تدريبه باستخدام جميع البيانات المتاحة. سيستغرق هذا عادةً الكثير من الوقت وموارد الحوسبة، لذلك يتم عادةً بدون اتصال بالإنترنت (offline learning).

أولًا يتم تدريب النظام ثم يتم إطلاقه في الإنتاج ويعمل هكذا دون أي تعلم بعد ذلك؛ إنه فقط يطبّق ما تعلّمه. وهذا ما يسمى التعلم دون اتصال بالإنترنت.

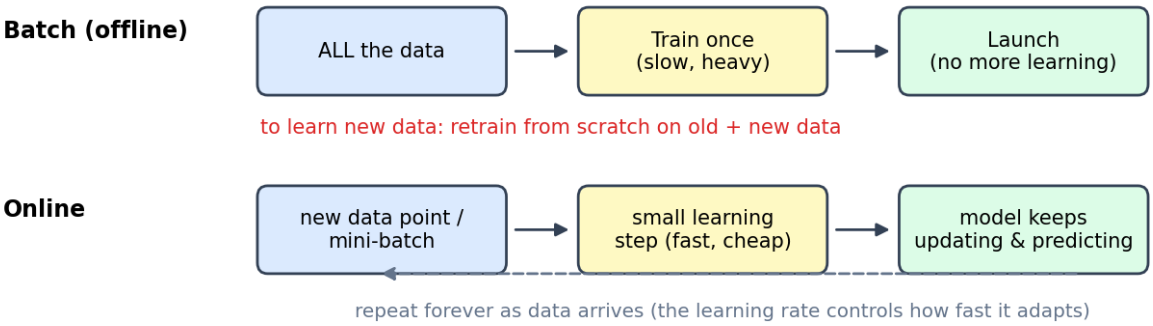
إذا كنت تريد أن يتعرف نظام التعلم الدفعي على البيانات الجديدة (مثل نوع جديد من الصور أو الرسائل)، فعليك إعادة تدريب نسخة جديدة من النظام من الصفر على مجموعة البيانات الكاملة (البيانات الجديدة والقديمة)، ثم استبدال النظام القديم بالنظام الجديد. (هذا الحل الوحيد إذا كنت تريده أن يتكيف مع التغيّر.)

من كشكولك

> *Online learning: In it, you train the system incrementally by feeding it data instances sequentially, either individually or by small groups called mini-batches. Each learning step is fast and cheap, so the system can learn about new data on the fly, as it arrives.*

في التعلم عبر الإنترنت تقوم بتدريب النظام بشكل تدريجي عن طريق تزويده بمثيلات البيانات بشكل تسلسلي، إما بشكل فردي أو بواسطة مجموعات صغيرة تسمى mini-batches. كل خطوة تعلم سريعة ورخيصة، لذلك يمكن للنظام التعرف على البيانات الجديدة أثناء وصولها.

إذا كان لديك موارد حوسبة محدودة، فبمجرد أن يتعلم نظام التعلم عبر الإنترنت من البيانات الجديدة، فإنه لا يحتاج إليها بعد الآن، لذا يمكنك التخلص منها (ويمكن أن يوفر هذا مساحة هائلة).

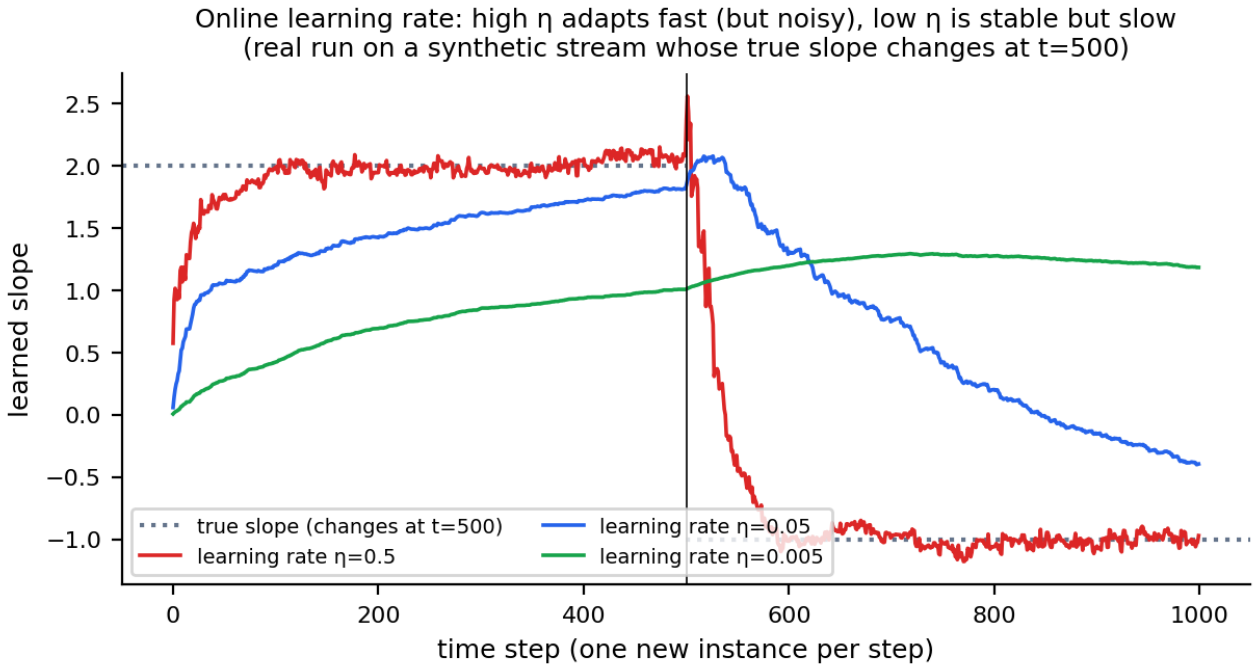


الفرق في الشكل: Batch بيتدرب مرة واحدة على كل الداتا وبعدين بيتجمّد، وOnline بيتحدّث باستمرار مع كل داتا جديدة.

من كشكولك

> *One important parameter of online learning systems is how fast they should adapt to changing data: this is called the learning rate.*

أحد العناصر المهمة لأنظمة التعلم عبر الإنترنت هو مدى سرعة تكيّفها مع البيانات المتغيرة، وهذا ما يسمى معدل التعلّم (learning rate). إذا قمت بتعيين معدل تعلم مرتفع فسيتكيف نظامك بسرعة مع البيانات الجديدة، ولكنه سيميل إلى نسيان البيانات القديمة بسرعة. على العكس من ذلك، إذا قمت بتعيين معدل تعلم منخفض فسيتعلم النظام بشكل أبطأ، ولكنه سيكون أقل حساسية للضوضاء في البيانات الجديدة.



نفس الفكرة بالتجربة: 3 قيم لـ η على stream بيتغيّر فيه الميل الحقيقي عند t=500. الأحمر (η كبير) لحق التغيير بسرعة بس فيه اهتزاز، والأخضر (η صغير) ثابت لكن لسه بيحاول يلحق في آخر الـ stream.

إضافة

في الكتاب كمان: الـ online learning بيتستخدم مع داتا ضخمة جدًا مش هتتحمّل على الذاكرة مرة واحدة، وده اسمه out-of-core learning: النظام بيحمّل جزء من الداتا ويتدرب عليه ويكرر لحد ما يخلص كل الداتا (برضه بيتعمل offline، فالاسم "online" مضلل شوية). وخطر مهم: لو داتا فاسدة دخلت النظام، الأداء هيقع بسرعة؛ لازم تراقب النظام وتوقف التعلم (وممكن تعمل rollback) لو لاحظت هبوط في الأداء.

9 الـ Instance-Based مقابل الـ Model-Based Learning

من كشكولك

هناك طريقة أخرى لتصنيف أنظمة التعلم الآلي وهي كيفية تعميمها (generalize). معظم مهام التعلم الآلي حول إجراء تنبؤات. هذا يعني أنه بالنظر إلى عدد من أمثلة التدريب، يحتاج النظام إلى أن يكون قادرًا على التعميم على أمثلة لم يرها من قبل. وجود مقياس أداء جيد على بيانات التدريب أمر جيد، لكنه غير كافٍ؛ الهدف الحقيقي هو الأداء الجيد على الحالات الجديدة.

هناك طريقتان رئيسيتان للتعميم:

من كشكولك

> *Instance-based learning: the system learns the examples by heart, then generalizes to new cases using a similarity measure.*

① **التعلم القائم على المثيل:** يتعلم النظام الأمثلة عن ظهر قلب، ثم يعممها على حالات جديدة باستخدام مقياس التشابه.

> *Model-based learning: build a model of these examples, then use that model to make predictions.*

② **التعلم القائم على النموذج:** بناء نموذج لهذه الأمثلة، ثم استخدام هذا النموذج لعمل التنبؤات.

من كشكولك

> *The linear regression algorithm: comes in, you feed it your training examples and it finds the parameters that make the linear model fit best to your data. This is called training the model.*

يأتي دور خوارزمية الانحدار الخطي: تقوم بتزويدها بأمثلة التدريب الخاصة بك، وتجد المعاملات التي تجعل النموذج الخطي يناسب بياناتك بشكل أفضل. وهذا ما يسمى تدريب النموذج. (يُستخدم الـ linear regression لما تكون العلاقة بين الـ `X` والـ `y` شبه خطية؛ لتوقع سعر مثلًا، لما يكون عندك بيانات كتير وعايز الموديل يتعلم منها، مش يقارن بينها زي KNN.)

$$\text{life_satisfaction} = \theta_0 + \theta_1 \times \text{GDP_per_capita}$$

```
import pandas as pd
from sklearn.linear_model import LinearRegression
from sklearn.neighbors import KNeighborsRegressor

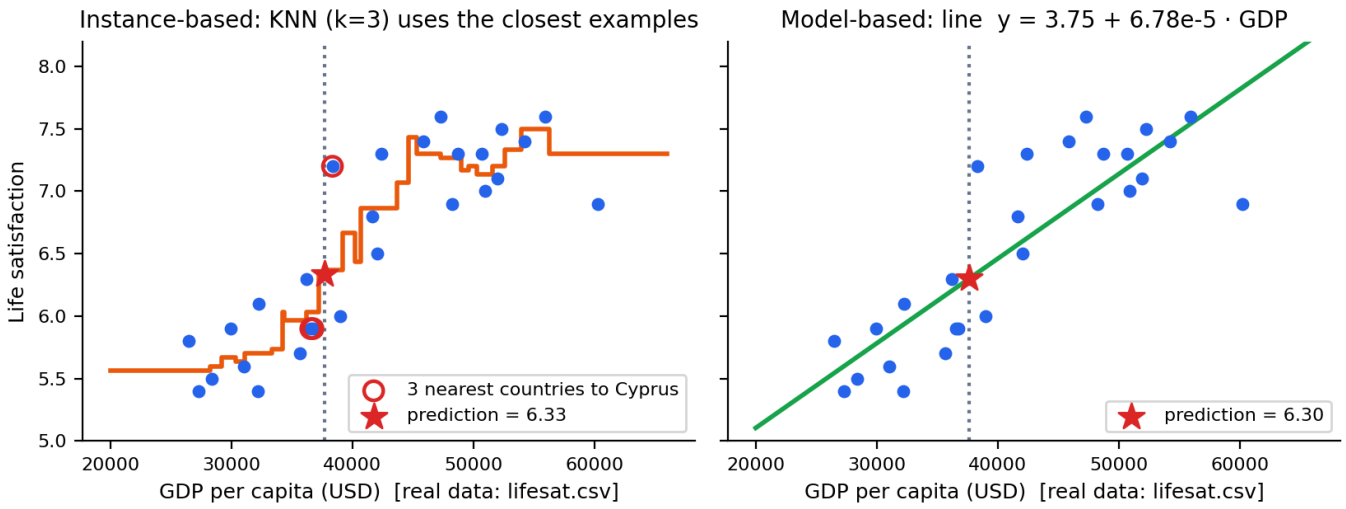
lifesat = pd.read_csv("lifesat.csv")                # the book's data: 27 countries
X = lifesat[["GDP per capita (USD)"]].values
y = lifesat[["Life satisfaction"]].values

X_new = [[37_655.2]]                                 # Cyprus' GDP per capita

model = LinearRegression().fit(X, y)                 # model-based
print(model.intercept_, model.coef_)                 # theta0, theta1
print(model.predict(X_new))

knn = KNeighborsRegressor(n_neighbors=3).fit(X, y)   # instance-based
print(knn.predict(X_new))
```

```
Output (real run)
[3.7490] [[6.7789e-05]]
[[6.3017]]
[[6.3333]]
```



نفس الداتا الحقيقية بالطريقتين. KNN (instance-based): بيدوّر على أقرب 3 دول لقبرص في الـ GDP (إسرائيل وليتوانيا وسلوفينيا) وبياخد متوسط الـ life satisfaction بتاعتهم = 6.33. Linear Regression (model-based): بيتعلّم خط بـ parameters ويرسم عليه = 6.30. النتيجتين قريبين بس الفكرة مختلفة.

إضافة

الفرق في الجوهر: الـ KNN **بيحفظ** كل الأمثلة (ومحتاج يفضل شايلهم) ويقارن بيهم وقت التنبؤ. الـ Linear Regression **بيلخّص** الأمثلة في رقمين بس (`θ0` و`θ1`) وبعد كده ممكن ترمي الداتا. والأرقام في المربع الأخضر طلعت زي الكتاب بالظبط: `θ0 = 3.75` و`θ1 = 6.78e-5`، والتوقع `6.30`.

من كشكولك

Cost function

Cost Function: هي بتقيس (مدى دقة جودة العلاقة بين features و labels).

- لو قيمة الـ cost function **عالية** ← يبقى الموديل اتعلّم علاقة ضعيفة أو غير صحيحة.
- لو **منخفضة** ← يبقى الموديل اتعلّم العلاقة بشكل جيد تقريبًا.

- يعني هو بيقيس مدى دقة الـ Parameters اللي الموديل اتعلمها أثناء التدريب في تمثيل العلاقة بين الـ labels وfeatures.

$$J(\theta) = \frac{1}{m} \sum_{i=1}^{m} (\theta^T \mathbf{x}^{(i)} - y^{(i)})^2$$

hyperparameter tuning: عملية ضبط وتحسين إعدادات الموديل (الإعدادات اللي إنت بتحددها قبل التدريب، مش اللي الموديل بيتعلمها).

10 مقدمة عن الـ Gradient Descent

من كشكولك

> *Gradient descent: is a very generic optimization algorithm capable of finding optimal solutions to a wide range of problems.*

الانحدار التدريجي: هو خوارزمية تحسين عامة جدًا قادرة على إيجاد حلول مثالية لمجموعة واسعة من المشكلات.

> *The general idea of gradient descent: is to tweak parameters iteratively in order to minimize a cost function.*

الفكرة العامة للانحدار التدريجي هي تعديل المعاملات بشكل متكرر من أجل تقليل دالة التكلفة.

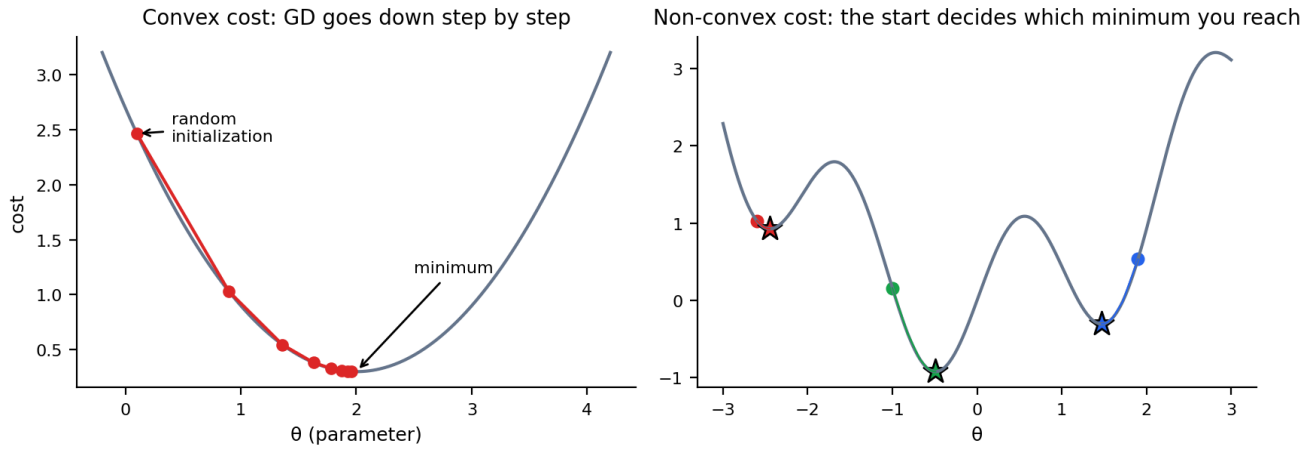
من كشكولك

> *What GD does? it measures the local gradient of the error function with regards to the parameter vector θ, and it goes in the direction of descending gradient. once the gradient is zero, you have reached a minimum.*

الانحدار التدريجي: فهو يقيس التدرّج المحلي لدالة الخطأ فيما يتعلق بمتجه المعاملات `θ`، ويتجه في اتجاه التدرّج التنازلي. بمجرد أن يصبح التدرّج صفرًا، تكون قد وصلت إلى الحد الأدنى.

بشكل ملموس: تبدأ بملء `θ` بقيم عشوائية (يسمى هذا Random initialization التهيئة العشوائية). ثم تحسّنها تدريجيًا، بخطوات صغيرة في كل مرة، حيث تحاول كل خطوة تقليل دالة التكلفة (مثل MSE) حتى تتقارب الخوارزمية إلى الحد الأدنى.

$$\theta^{(\text{next step})} = \theta - \eta \nabla_\theta J(\theta)$$



شمال: الـ cost دالة محدبة (convex): من أي نقطة بداية بتنزل لنفس الـ minimum. يمين: لو الـ cost مش محدبة، نقطة البداية بتحدد أنهي minimum توصله: الأحمر والأزرق علقوا في local minima، والأخضر وصل للـ global minimum. (تشغيل حقيقي)

من كشكولك

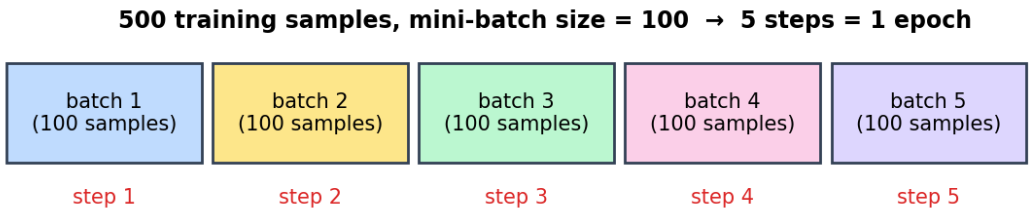
> *An important parameter in GD is the size of the steps, determined by the learning rate. If the learning rate is too small, then the algorithm will have to go through many iterations to converge, which will take along time.*

يعد حجم الخطوات، الذي يحدده معامل معدل التعلم (learning rate)، مهمًا في الانحدار التدريجي. إذا كان معدل التعلم صغيرًا جدًا، فسيتعين على الخوارزمية المرور بالعديد من التكرارات للتقارب، وهذا سيستغرق وقتًا طويلًا.

ملاحظة أخرى: إذا كان معدل التعلم مرتفعًا جدًا، فقد تقفز عبر الوادي وتنتهي في الجانب الآخر، وربما حتى في مكان أعلى مما كنت عليه من قبل. قد يؤدي هذا إلى تباعد الخوارزمية (يقفز لأكبر وأكبر) وفشلها في إيجاد حل جيد.

من كشكولك

ملاحظة عن الـ mini-batch والـ epoch (من ورقتك): لو عندي 500 داتا وبستخدم mini-batch حجمها 100، يبقى الـ epoch الواحدة فيها 5 steps (لأن `500 = 5 × 100`) لأن كل جزء (كل 100) بنخرج منه step واحد.



1 epoch = one full pass over all the data

شكل الملاحظة: كل batch = step واحد. الـ epoch هي مرور كامل على كل الداتا.

إضافة

(راجع شابتر 4 للتفاصيل الكاملة: Batch و Stochastic و Mini-batch GD، والـ learning schedule، والـ scaling.)
الحاجة الجديدة هنا: الـ cost اللي بنتعامل معاها في الـ Linear Regression محدبة (convex) فمفيش خطر local minima، لكن في الـ Neural Networks لأ، ودي اللي الرسمة اليمين بتوضّحها.

11 التحديات الرئيسية في الـ ML

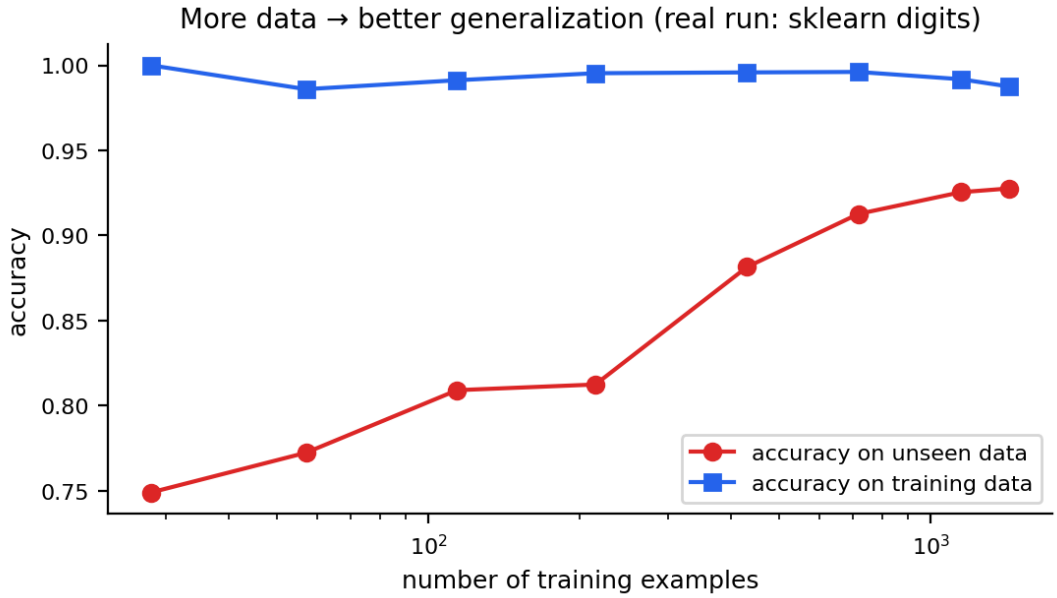
من كشكولك

باختصار، نظرًا لأن مهمتك الرئيسية هي اختيار خوارزمية تعلم وتدريبها على بعض البيانات، فإن الشيئين اللذين يمكن أن يحدث خطأ فيهما هما "الخوارزمية السيئة" و"البيانات السيئة". لنبدأ بأمثلة على **البيانات السيئة**.

من كشكولك

① Insufficient quantity of training data (كمية غير كافية من بيانات التدريب)

لكي يتعلم الطفل الصغير ما هي التفاحة، كل ما يتطلبه الأمر هو أن تشير إلى التفاحة وتقول لها "تفاحة" (وتكرر عدة مرات). لكن لم يصل التعلم الآلي إلى هذه المرحلة بعد؛ يتطلب الأمر الكثير من البيانات حتى تعمل معظم خوارزميات التعلم الآلي بشكل صحيح. حتى بالنسبة للمشكلات البسيطة جدًا تحتاج عادةً إلى الآلاف من الأمثلة.



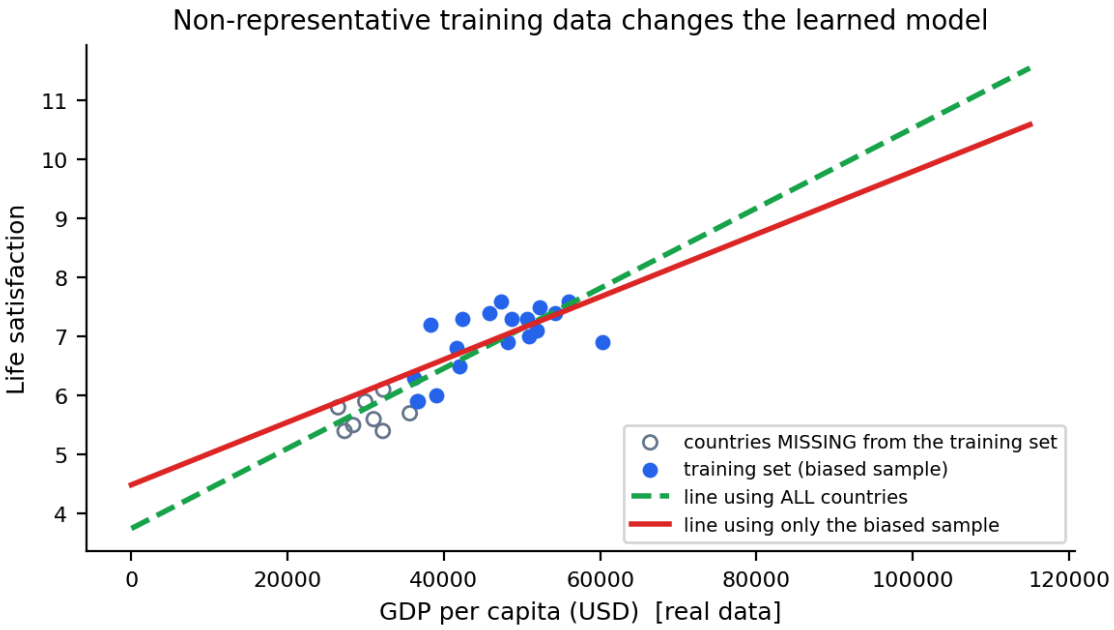
تجربة حقيقية على digits: الدقة على داتا مش شايفاها بتطلع من 75% بحوالي 28 مثال تدريب لـ 93% بحوالي 1437 مثال. نفس الخوارزمية بالظبط، الفرق الوحيد كمية الداتا.

من كشكولك

② Nonrepresentative training data (بيانات تدريب غير تمثيلية)

> *In order to generalize well, it is crucial that your training data be representative of the new cases you want to generalize to. This is true whether you use instance-based learning or model-based learning.*

من أجل التعميم بشكل جيد، من الضروري أن تكون بيانات التدريب ممثلة للحالات الجديدة التي تريد التعميم عليها. هذا صحيح سواء كنت تستخدم التعلم القائم على المثيل أو التعلم القائم على النموذج.



تجربة حقيقية على lifesat.csv: لما شلنا الدول الأفقر من الـ training set، الميل المتعلَّم اتغيّر من 6.78e-5 لـ 5.30e-5. الموديل مش غلط، الداتا اللي اتدرب عليها هي اللي مش بتمثل الواقع.

من كشكولك

③ Poor quality data (بيانات رديئة)

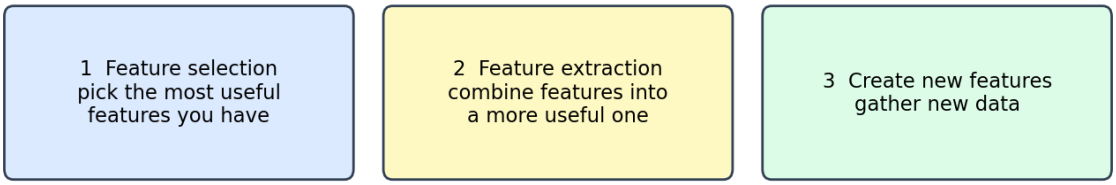
الواضح إنه إذا كانت بيانات التدريب الخاصة بك مليئة بالأخطاء والقيم المتطرفة والضوضاء (مثلًا: بسبب ضعف جودة القياسات)، فسيجعل ذلك من الصعب على النظام اكتشاف الأنماط الأساسية (detect the underlying patterns)، وبالتالي يقل احتمال أداء نظامك بشكل جيد. غالبًا ما يكون من المفيد قضاء الوقت في تنظيف بيانات التدريب.

من كشكولك

④ Irrelevant features (الميزات غير ذات الصلة)

إذا قلت garbage in, garbage out: بيانات غير مهمة خرجت بيانات غير مهمة. لن يكون نظامك قادرًا على التعلم إلا إذا كانت بيانات التدريب تحتوي على عدد كافٍ من الميزات ذات الصلة وليس الكثير من الميزات غير ذات الصلة. ومن نجاح أي مشروع تعلّم آلي هو التوصل إلى مجموعة جيدة من الميزات للتدريب عليها. تتضمن هذه العملية هندسة الميزات (Feature engineering) وما يلي:

1. **Feature selection:** اختيار الميزات الأكثر فائدة للتدريب عليها من بين الميزات الموجودة.
2. **Feature extraction:** دمج الميزات الموجودة لإنتاج ميزة أكثر فائدة.
3. **إنشاء ميزات جديدة** من خلال جمع بيانات جديدة.



الـ 3 طرق لتحسين الـ features (Feature engineering).

من كشكولك

كل اللي فاتت كانت أمثلة عن **البيانات السيئة**، ودلوقتي هنبدأ على بعض الأمثلة على **الخوارزميات السيئة**.

من كشكولك

⑤ Overfitting the training data (الإفراط في التجهيز / فرط التخصيص)

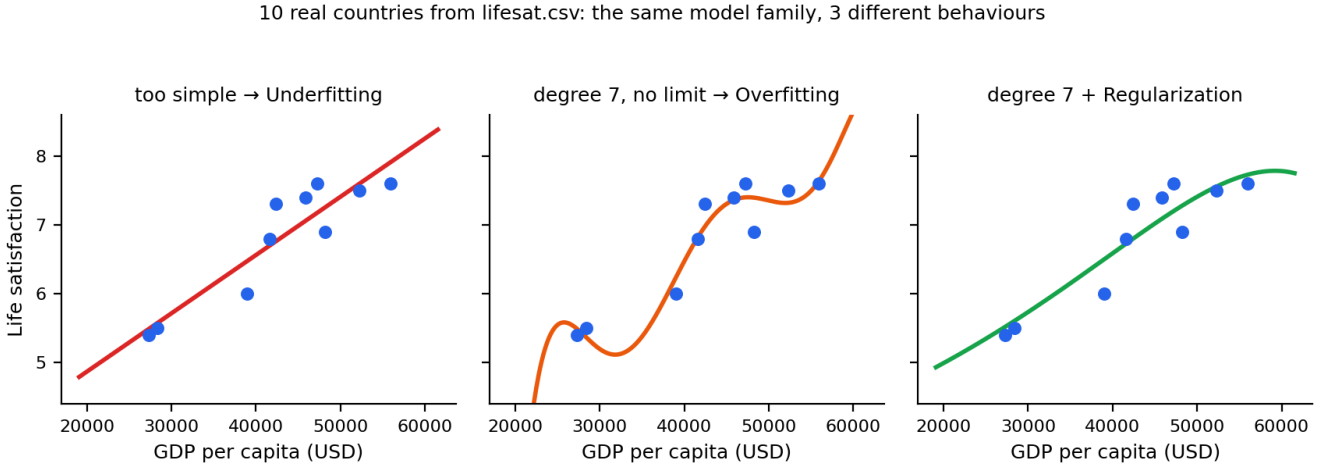
> *Overfitting the training data: it means that the model performs well on the training data, but it does not generalize well.*

الإفراط في التعلّم: يعني أن النموذج يعمل بشكل جيد على بياناته التدريبية لكنه لا يُعمّم جيدًا. (يعني إن الموديل اتدرب كتير على الداتا لدرجة إنه بصمها، يعني لو نفس الشكل يعرفه لو غيرها لأ.)

> *Overfitting happens when the model is too complex relative to the amount and noisiness of the training data.*

يحدث الإفراط في التجهيز عندما يكون النموذج معقدًا للغاية بالنسبة لكمية وتشويش بيانات التدريب. الحلول الممكنة هي:

1. **تبسيط النموذج** عن طريق اختيار نموذج بمعاملات أقل (fewer parameters)، أو عن طريق تقليل عدد السمات (attributes) في بيانات التدريب، أو عن طريق **تقييد النموذج** (constraining the model).
2. **جمع المزيد من بيانات التدريب.**
3. **تقليل التشويش في بيانات التدريب** (على سبيل المثال: إصلاح أخطاء البيانات وإزالة القيم المتطرفة).



تجربة حقيقية على 10 دول من lifesat.csv: الخط المستقيم بسيط جدًا (Underfitting)، polynomial بدرجة 7 بدون قيود بيلف حوالين كل نقطة (Overfitting)، ونفس الـ polynomial لكن مع Regularization بيتهدّى ويفضل مرن.

من كشكولك

> *Constraining a model to make it simpler and reduce the risk of overfitting is called regularization.*

يطلق على تقييد النموذج لجعله أبسط وتقليل خطر التجاوز اسم التنظيم (Regularization) (يُستخدم كمان لتبسيط/لعمل simplify).

ملاحظة: الـ Parameters دول هي حاجات في الموديل اللي بيقدر يظبطهم وكل ده بيطلع النواتج وهو اللي بيتعلمها؛ أما الـ hyperparameter فهي حاجة إنت اللي بتتحكم فيها (الإنت اللي بتحط فيها قيمة)، زي مقدار الـ regularization وزي الـ learning rate بتاع الـ GD؛ ولازم تحددها قبل التدريب.

(*) أي حاجة إنت اللي بتخليها للموديل hyperparameter مش parameter.

من كشكولك

⑥ Underfitting the training data (نقص ملاءمة بيانات التدريب)

> *Underfitting the training data: it occurs when your model is too simple to learn the underlying structure of the data.*

نقص ملاءمة بيانات التدريب: يحدث عندما يكون نموذجك بسيطًا جدًا بحيث لا يمكنه تعلّم البنية الأساسية للبيانات. (يعني الموديل مش بيتدرب كفاية على الداتا، أو إن الداتا مش كافية وصغيرة جدًا.)

الخيارات الرئيسية لحل هذه المشكلة هي:

1. اختيار نموذج أكثر قوة، مع المزيد من المعاملات.
2. إعطاء ميزات أفضل لخوارزمية التعلم (feature engineering).
3. تقليل القيود المفروضة على النموذج (على سبيل المثال: تقليل معامل التنظيم الفائق).

إضافة

	Overfitting	Underfitting
الموديل	معقّد زيادة	بسيط زيادة
الأداء على الـ training	ممتاز	سيء
الأداء على بيانات جديدة	سيء	سيء
الحلول	موديل أبسط / داتا أكتر / تقليل الـ noise / Regularization أقوى	موديل أقوى / features أحسن / Regularization أضعف

الـ Regularization (hyperparameter) هو **السلاح الذي يعمل في الاتجاهين**: زوّده لو overfitting، قلّله لو underfitting. وبنتعمق فيه في شابتر 4.

12 Testing and Validating (الاختبار والتحقق)

من كشكولك

مجرد تدريب نموذج ثم تركه بدون اختبار فقط لا يكفي ("الأمل" في تعميمه على الحالات الجديدة). بل تريد تقييمه وضبطه بدقة إذا لزم الأمر.

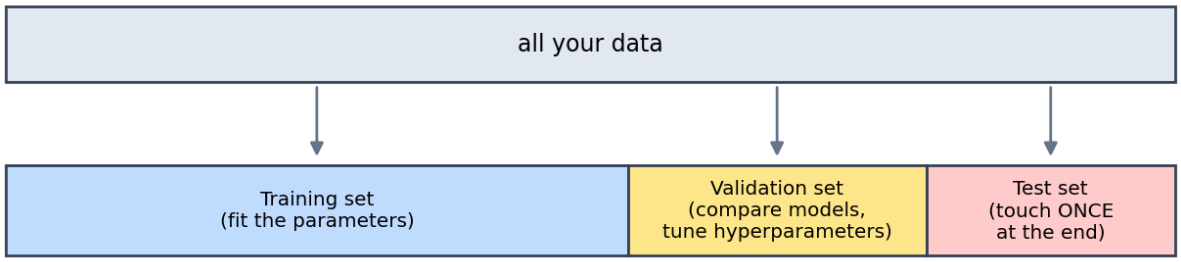
الطريقة الوحيدة لتعرف مدى جودة تعميم النموذج على الحالات الجديدة هي تجربته فعليًا على حالات جديدة. وأفضل طريقة لذلك هو تقسيم بياناتك إلى مجموعتين: مجموعة تدريب (training set) ومجموعة الاختبار (test set).

من كشكولك

> *The error rate on new cases is called generalization error, and by evaluating your model on the test set, you get an estimation of this error. This value tells you how well your model will perform on instances it has never seen before.*

يُطلق على معدل الخطأ في الحالات الجديدة خطأ التعميم (generalization error) (ومن خلال تقييم نموذجك على مجموعة الاختبار، تحصل على تقدير لهذا الخطأ). تخبرك هذه القيمة بمدى جودة أداء نموذجك على الحالات التي لم يرها من قبل.

إذا كان خطأ التدريب منخفضًا (أي أن نموذجك يرتكب أخطاء قليلة في مجموعة التدريب) ولكن خطأ التعميم مرتفع، فهذا يعني أن نموذجك يقوم بـ overfit لبيانات التدريب.



التقسيم الكامل: training لتدريب الـ parameters، validation لاختيار الموديل وضبط الـ hyperparameters، وtest مرة واحدة بس في الآخر لتقدير الـ generalization error.

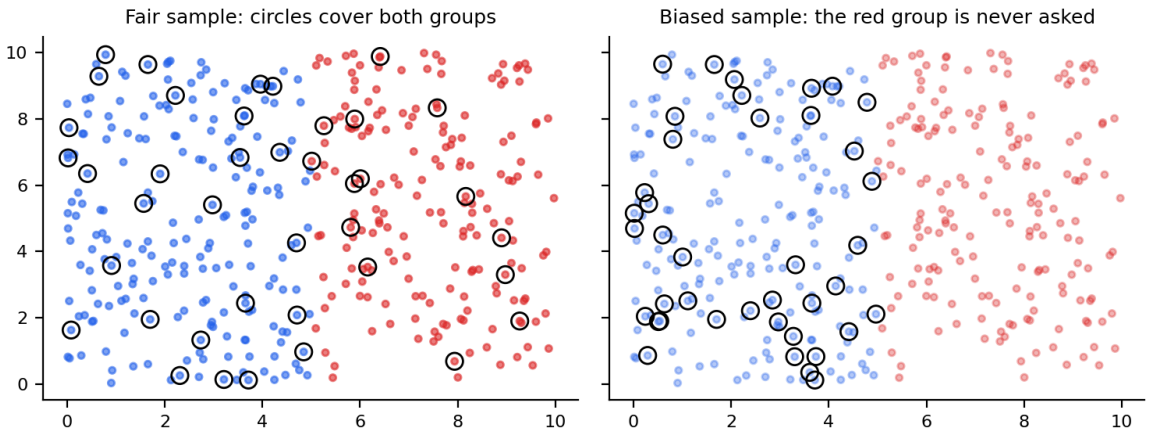
من كشكولك

Cross Validation: هو أسلوب لتقييم الموديل عن طريق تقسيم البيانات لعدة أجزاء والتدريب والاختبار عليهم بالتبادل للحصول على تقدير أكثر ثباتًا وأقرب للواقع للأداء.

من كشكولك

Data Mismatch: يعني إن الداتا اللي الموديل اتعلّم منها مختلفة عن الداتا اللي هيشتغل عليها في الواقع.

Sampling Bias: انحياز في اختيار العينة (Sample) بحيث إن العينة اللي اخترتها لا تمثّل الـ Population بشكل عادل (اتختارت Sample بطريقة غير صحيحة، فالـ Sample لا تمثل الـ Population) ← إذن النتائج / الموديل تكون متحيّزة.



شمال: عينة عادلة بتغطي المجموعتين. يمين: عينة متحيّزة (الأحمر ما اتسألش أبدًا) فأي موديل هيتعلم منها هيبقى متحيّز.

إضافة

نقطة مهمة من الكتاب: لو ضبطت الـ hyperparameters باستخدام الـ test set، هتحصل على تقدير متفائل زيادة للـ generalization error (الموديل اتظبط على الـ test نفسه). الحل: validation set (أو dev set) ثابتة للضبط، أو cross-validation، والـ test set لمرة واحدة فقط في الآخر. وفي حالة الـ data mismatch (مثلًا داتا التدريب صور من الإنترنت لكن المنتج هيشتغل على صور موبايل)، الكتاب بيقترح train-dev set جزء من داتا التدريب بنعزله عشان نعرف المشكلة من الموديل ولا من اختلاف الداتا.

وقاعدة عملية بيذكرها الكتاب: بنقسم عادة 80% / 20% (train / test)، ولو الداتا ضخمة جدًا (ملايين) ممكن نكتفي بـ 1% أو أقل للـ test.

13 أسئلة مراجعة سريعة

جاوب الأول في دماغك، وبعدين شوف الإجابات في الصفحة اللي بعدها.

1. مين أول واحد وضع مصطلح Machine Learning؟ وإيه تعريفه؟
2. اشرح تعريف Tom Mitchell (E, T, P) على مثال spam filter.
3. إمتى بيكون الـ ML الأنسب من البرمجة التقليدية؟ (4 حالات)
4. اذكر المعايير التلاتة لتصنيف أنظمة الـ ML.
5. إيه الفرق بين Classification و Regression؟ مثال لكل واحد.
6. اذكر 6 خوارزميات supervised من الكتاب.
7. إيه الفرق بين Supervised و Unsupervised؟
8. اذكر 3 مهام unsupervised رئيسية مع خوارزمية لكل واحدة.
9. إيه هي Dimensionality Reduction وليه مفيدة؟
10. إيه الفرق بين Anomaly detection و Novelty detection؟
11. إيه هو الـ Semi-supervised؟ مثال Google Photos.
12. إيه هو الـ Self-supervised؟
13. اشرح الـ Reinforcement Learning: agent, environment, action, reward, policy.
14. إيه الفرق بين Batch و Online learning؟
15. إيه هو الـ learning rate في الـ online learning؟ إيه اللي بيحصل لو عالي أو واطي؟
16. إيه هو الـ out-of-core learning؟
17. إيه الفرق بين Instance-based و Model-based؟ مثال لكل واحد.
18. إيه هي الـ Cost function؟ وإيه الفرق بين Parameter و Hyperparameter؟
19. اشرح فكرة Gradient Descent وإيه اللي بيحصل لو الـ learning rate صغير جدًا أو كبير جدًا؟
20. إيه هو الـ epoch؟ لو 500 داتا و mini-batch=100 كام step في الـ epoch؟
21. اذكر 4 تحديات خاصة بالبيانات و2 خاصة بالخوارزمية.
22. إيه الفرق بين Overfitting و Underfitting؟ وإيه حلول كل واحدة؟
23. إيه هو الـ Regularization؟
24. ليه بنقسم الداتا لـ train / validation / test؟ وإيه هو الـ generalization error؟
25. إيه هو الـ Sampling bias؟ والـ Data mismatch؟

14 إجابات أسئلة المراجعة

1. Arthur Samuel سنة 1959: "field of study that gives computers the ability to learn without being explicitly programmed".
2. البرنامج بيتعلم من خبرة E بالنسبة لمهمة T ومقياس أداء P لو أداؤه على T (مقاس بـ P) بيتحسن مع E. في الـ spam filter: T=تصنيف الإيميلات، E=إيميلات متصنفة قبل كده، P=نسبة التصنيف الصح.
3. (1) مشاكل محتاجة قواعد كتير/ضبط يدوي. (2) مشاكل معقدة مفيش ليها حل كويس بالطرق التقليدية. (3) بيئات متقلبة. (4) استخراج رؤى (insights) من داتا ضخمة.
4. (1) الإشراف البشري (supervised, unsupervised, semi, RL). (2) هل بيتعلم تدريجيًا (online) ولا دفعة واحدة (batch). (3) instance-based ولا model-based.
5. Classification بيتنبأ بفئة (spam/ham)، Regression بيتنبأ برقم (سعر عربية).
6. k-Nearest Neighbors, Linear Regression, Logistic Regression, SVMs, Decision Trees/Random Forests, Neural networks.
7. الـ Supervised داتاه فيها labels (الإجابات)، الـ Unsupervised مفيش labels والنظام بيتعلم من غير معلم.
8. Clustering (k-means), Visualization/dimensionality reduction (PCA), Association rule learning (Apriori) — وكمان Anomaly detection (Isolation Forest).
9. تقليل عدد الـ features مع الاحتفاظ بأكبر معلومات؛ بتسرّع التدريب، وتقلل خطر الـ overfitting، وتوفر مساحة.
10. Anomaly detection بتتدرب على داتا ممكن فيها شوية outliers. Novelty detection محتاجة training set نضيف من الحاجة الغريبة.
11. داتا فيها شوية labels ومعظمها من غير labels. مثال Google Photos: clustering لوش نفس الشخص ثم label واحد بس بيتعمم.
12. النظام بيولّد labels من داتا unlabeled نفسها (مثلًا يمسح جزء من الصورة ويحاول يخمّنه).
13. الـ agent بيراقب الـ environment ويعمل action ويحصل على reward أو penalty؛ والمطلوب يتعلم policy تحقق أكبر reward بمرور الوقت.
14. Batch: بيتدرب على كل الداتا مرة واحدة offline وبعدين يتجمّد، ولو داتا جديدة لازم إعادة تدريب من الصفر. Online: بيتعلم تدريجيًا مع كل داتا/mini-batch.
15. سرعة تكيّف النظام مع الداتا المتغيرة. عالي: يتكيف بسرعة وينسى القديم بسرعة (وحساس للـ noise). واطي: أبطأ لكن أكتر ثباتًا.
16. تدريب على داتا ضخمة مش بتتحمل في الذاكرة: نحمّل جزء ونتدرب عليه ونكرر لحد ما تخلص (offline برضه).
17. Instance-based بيحفظ الأمثلة ويقارن بالتشابه (KNN). Model-based بيبني نموذج بـ parameters ويتنبأ بيه (Linear Regression).
18. Cost function = دالة بتقيس سوء الموديل بناءً على الـ parameters. Parameters: الموديل بيتعلمها. Hyperparameters: إنت بتحددها قبل التدريب.
19. GD بيعدّل الـ parameters تدريجيًا عكس اتجاه الـ gradient لحد ما يوصل لـ minimum. η صغير جدًا = بطيء جدًا. η كبير = يقفز فوق الوادي وممكن يتباعد.
20. epoch = مرور كامل على الداتا. 500 ÷ 100 = 5 steps.

21. داتا: كمية غير كافية، غير تمثيلية، رديئة، features غير مهمة. خوارزمية: overfitting و underfitting.
22. Overfitting: الموديل بصم الـ training ومش بيعمّم (الحل: أبسط/داتا أكتر/تنضيف/regularization). Underfitting: بسيط زيادة (الحل: أقوى/features أحسن/تقليل القيود).
23. تقييد الموديل لتبسيطه وتقليل خطر الـ overfitting.
24. عشان نقيس الأداء على داتا جديدة: training للتدريب، validation لاختيار الموديل/ضبط hyperparameters، test مرة واحدة للـ generalization error (معدل الخطأ على الحالات الجديدة).
25. Sampling bias: العينة ما بتمثلش الـ population. Data mismatch: داتا التدريب مختلفة عن داتا الواقع اللي هيشتغل عليها.